

### Teoría

El **Teorema del Límite Central** nos dice que, si  $X_1, X_2, X_3, \dots, X_n$  son una muestra aleatoria de una población infinita con media  $\mu$ , varianza  $\sigma^2$ , y generatriz de momentos  $M_X(t)$ , entonces la distribución de

$$Z = \frac{\bar{X} - \mu}{\sigma/\sqrt{n}}$$

cuando  $n \rightarrow \infty$ , es la distribución normal estándar.

### Simulación

Para ilustrar lo visto en la teoría, se realizó una simulación siguiendo los siguientes pasos:

1. Se tomaron  $N = 10,000$  datos aleatorios de una distribución normal utilizando la función `rnorm`.
2. Se obtiene el promedio de estos datos.
3. Se repiten los pasos 1 y 2  $M$  veces y se hace un histograma de los promedios obtenidos para  $M_1 = 500$ ,  $M_2 = 1,000$ ,  $M_3 = 5,000$  y  $M_4 = 10,000$ .
4. Se repiten los pasos del 1 al 3 para otras tres distribuciones.
5. Comparamos resultados.


Para la simulación del muestreo sobre una distribución normal estándar se utilizó el siguiente script en lenguaje R. Nota:  $\mu = 0$  y  $\sigma^2 = 1$ .

```
# Parámetros de muestreo de datos
N <- 10000
M1 <- 500
M2 <- 1000
M3 <- 5000
M4 <- 10000

# Método de Montecarlo para datos tomados de la distribución
# normal
v1 <- vector()
v2 <- vector()
v3 <- vector()
v4 <- vector()
for(i in 1:M1){
  x <- rnorm(N)
  v1[i] <- (mean(x)) / (1/sqrt(N))
}
```

```
}  
for(i in 1:M2){  
  x <- rnorm(N)  
  v2[i] <- (mean(x))/(1/sqrt(N))  
}  
for(i in 1:M3){  
  x <- rnorm(N)  
  v3[i] <- (mean(x))/(1/sqrt(N))  
}  
for(i in 1:M4){  
  x <- rnorm(N)  
  v4[i] <- (mean(x))/(1/sqrt(N))  
}  
# Histogramas para observar y comparar las distribuciones de las  
# muestras  
par(mfrow = c(2,2), mar=c(4,4,4,4))  
hist(v1, main=NULL, xlim=c(-0.04,0.04), xlab="(a)",  
     col="darkgreen")  
hist(v2, main=NULL, xlim=c(-0.04,0.04), xlab="(b)",  
     col="darkgreen")  
hist(v3, main=NULL, xlim=c(-0.04,0.04), xlab="(c)",  
     col="darkgreen")  
hist(v4, main=NULL, xlim=c(-0.04,0.04), xlab="(d)",  
     col="darkgreen")
```

El script anterior nos arroja como datos de salida los siguientes histogramas.




**Figura 1:** Histogramas para (a) 500 repeticiones, (b) 1,000 repeticiones, (c) 5,000 repeticiones y (d) 10,000 repeticiones del promedio de un muestreo de 1,000 datos de una distribución normal estándar.

Para repetir la simulación con una distribución uniforme, hacemos uso de la función `runif` de R. Los histogramas que nos arroja el script están a continuación. Nota:  $\mu = 0.5$  y  $\sigma^2 = 1/12$ .

## Teorema del Límite Central

```
# Parámetros de muestreo de datos
N <- 10000
M1 <- 500
M2 <- 1000
M3 <- 5000
M4 <- 10000

# Método de Montecarlo para datos tomados de la distribución
# uniforme con alpha = 0 y beta = 1
v1 <- vector()
v2 <- vector()
v3 <- vector()
v4 <- vector()
for(i in 1:M1){
  x <- runif(N)
  v1[i] <- (mean(x)-0.5) / (sqrt(1/12)/sqrt(N))
}
for(i in 1:M2){
  x <- runif(N)
  v2[i] <- (mean(x)-0.5) / (sqrt(1/12)/sqrt(N))
}
for(i in 1:M3){
  x <- runif(N)
  v3[i] <- (mean(x)-0.5) / (sqrt(1/12)/sqrt(N))
}
for(i in 1:M4){
  x <- runif(N)
  v4[i] <- (mean(x)-0.5) / (sqrt(1/12)/sqrt(N))
}
par(mfrow = c(2,2), mar=c(4,4,4,4))
hist(v1, main=NULL, xlim=c(-4,4), xlab="(a)", col="darkgreen")
hist(v2, main=NULL, xlim=c(-4,4), xlab="(b)", col="darkgreen")
hist(v3, main=NULL, xlim=c(-4,4), xlab="(c)", col="darkgreen")
hist(v4, main=NULL, xlim=c(-4,4), xlab="(d)", col="darkgreen")
```



**Figura 2:** Histogramas para (a) 500 repeticiones, (b) 1,000 repeticiones, (c) 5,000 repeticiones y (d) 10,000 repeticiones del promedio de un muestreo de 1,000 datos de una distribución uniforme de 0 a 1.

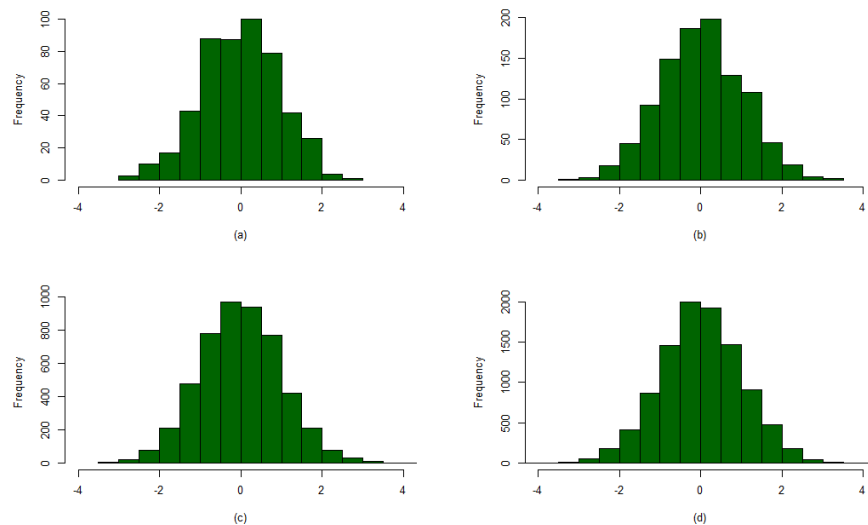
## Teorema del Límite Central

---

De la misma forma, hacemos uso de la función `rchisq` para realizar el mismo experimento con la distribución Ji Cuadrada. Los histogramas que nos arroja el script en R son los mostrados a continuación. Nota:  $\mu = 3$  y  $\sigma^2 = 6$ .

```
# Parámetros de muestreo de datos
N <- 10000
M1 <- 500
M2 <- 1000
M3 <- 5000
M4 <- 10000

# Método de Montecarlo para datos tomados de la distribución
# chi cuadrada con nu = 3
v1 <- vector()
v2 <- vector()
v3 <- vector()
v4 <- vector()
for(i in 1:M1){
  x <- rchisq(N, 3)
  v1[i] <- (mean(x)-3)/(sqrt(2*3)/sqrt(N))
}
for(i in 1:M2){
  x <- rchisq(N, 3)
  v2[i] <- (mean(x)-3)/(sqrt(2*3)/sqrt(N))
}
for(i in 1:M3){
  x <- rchisq(N, 3)
  v3[i] <- (mean(x)-3)/(sqrt(2*3)/sqrt(N))
}
for(i in 1:M4){
  x <- rchisq(N, 3)
  v4[i] <- (mean(x)-3)/(sqrt(2*3)/sqrt(N))
}
par(mfrow = c(2,2), mar=c(4,4,4,4))
hist(v1, main=NULL, xlim=c(-4,4), xlab="(a)", col="darkgreen")
hist(v2, main=NULL, xlim=c(-4,4), xlab="(b)", col="darkgreen")
hist(v3, main=NULL, xlim=c(-4,4), xlab="(c)", col="darkgreen")
hist(v4, main=NULL, xlim=c(-4,4), xlab="(d)", col="darkgreen")
```



**Figura 3:** Histogramas para (a) 500 repeticiones, (b) 1,000 repeticiones, (c) 5,000 repeticiones y (d) 10,000 repeticiones del promedio de un muestreo de 1,000 datos de una distribución ji cuadrada con 3 grados de libertad.

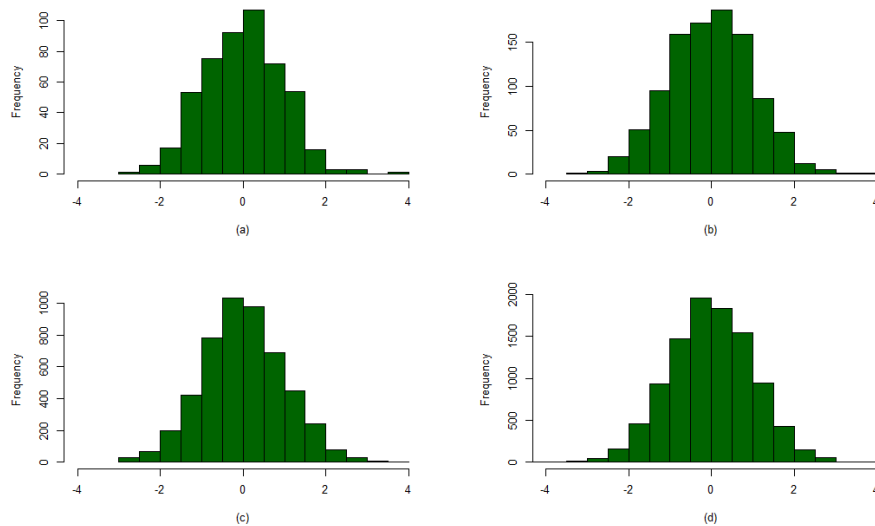
Por último, realizamos los mismos pasos para la distribución exponencial usando la función `rexp` de R para obtener los siguientes histogramas. Nota:  $\mu = 2$  y  $\sigma^2 = 4$ .

```
# Parámetros de muestreo de datos
N <- 10000
M1 <- 500
M2 <- 1000
M3 <- 5000
M4 <- 10000

# Método de Montecarlo para datos tomados de la distribución
# exponencial con teta = 2
v1 <- vector()
v2 <- vector()
v3 <- vector()
v4 <- vector()
for(i in 1:M1){
  x <- rexp(N, rate=0.5)
  v1[i] <- (mean(x)-2) / (2/sqrt(N))
}
for(i in 1:M2){
  x <- rexp(N, rate=0.5)
  v2[i] <- (mean(x)-2) / (2/sqrt(N))
}
for(i in 1:M3){
  x <- rexp(N, rate=0.5)
  v3[i] <- (mean(x)-2) / (2/sqrt(N))
}
for(i in 1:M4){
  x <- rexp(N, rate=0.5)
```

## Teorema del Límite Central

```
v4[i] <- (mean(x)-2)/(2/sqrt(N))
}
par(mfrow = c(2,2), mar=c(4,4,4,4))
hist(v1, main=NULL, xlim=c(-4,4), xlab="(a)", col="darkgreen")
hist(v2, main=NULL, xlim=c(-4,4), xlab="(b)", col="darkgreen")
hist(v3, main=NULL, xlim=c(-4,4), xlab="(c)", col="darkgreen")
hist(v4, main=NULL, xlim=c(-4,4), xlab="(d)", col="darkgreen")
```



**Figura 4:** Histogramas para (a) 500 repeticiones, (b) 1,000 repeticiones, (c) 5,000 repeticiones y (d) 10,000 repeticiones del promedio de un muestreo de 1,000 datos de una distribución exponencial con  $\theta = 2$ .

## Comentarios

Si bien las simulaciones no son suficientes para demostrar el Teorema del Límite Central, nos ayudan a ver que hay una tendencia a parecerse a la distribución normal estándar cuando  $M$  tiende a infinito.